Indexation d'un texte

Introduction

Nous allons utiliser les propriétés des arbres binaires de recherche pour implémenter un exemple d'indexation et de recherche sur un fichier contenant un texte quelconque.

L'arbre binaire de recherche contiendra tous les mots présents dans le texte à indexer :

- chaque nœud de l'arbre contient un mot, ainsi que la liste des positions du mot dans le texte
- une position correspond à un numéro de ligne, un ordre dans la ligne (1 pour le premier mot de la ligne, 2 pour le deuxième mot, etc...), un numéro de phrase
- le texte ne contient que des majuscules, des minuscules et des points (séparateur de phrases)

A. Structures de données

Implémenter les structures de données suivantes (ainsi que les typedef correspondants):

- la structure Position qui comporte les champs :
 - numero ligne de type int
 - ordre de type int
 - numero phrase de type int
 - suivant de type struct Position*
- la structure ListePosition qui comporte les champs :
 - debut de type struct Position*
 - nb elements de type int
- la structure NoeudABR qui comporte les champs :
 - mot de type char*
 - positions de type ListePosition
 - filsGauche de type struct NoeudABR*
 - filsDroit de type struct NoeudABR*
- la structure **ArbreBR** qui comporte le champ :
 - racine de type struct NoeudABR*
 - nb mots differents detype int
 - nb mots total detype int

B. Fonctions de base à implémenter

1. Fonction qui crée une liste de positions vide (renvoie NULL si échec):

```
ListePosition *creer liste positions()
```

2. Fonction qui ajoute un élément dans une liste de positions en respectant l'ordre du mot dans le texte (renvoie 1 en cas de succès, 0 sinon):

```
int ajouter_position(ListePosition *listeP, int ligne, int ordre)
```

NF16 - TP 4 - Les ABR

3. Fonction qui crée un ABR vide (renvoie NULL en cas d'échec):

ArbreBR *creer abr()

4. Fonction qui ajoute un nœud dans l'arbre en respectant les règles d'insertion dans les ABR (renvoie 1 en cas de succès, 0 sinon):

```
int ajouter_noeud(ArbreBR *arbre, char *mot, int ligne, int ordre)
```

On se basera sur l'ordre lexicographique pour déterminer la position d'un nœud dans l'arbre :

avion < bagage < bateau < cabane < cabine <voiture=VoiTure

5. Fonction qui lit un fichier et ajoute tous les mots dans un ABR (renvoie le nombre de mots lus) :

```
int charger_fichier(ArbreBR *arbre, char *filename)
```

6. Fonction qui recherche un nœud dans un ABR (renvoie NULL si nœud non trouvé):

```
NoeudABR *rechercher noeud(ArbreBR *arbre, char *mot)
```

7. Procédure qui affiche la liste des mots classée par ordre alphabétique (choisissez le bon type de parcours des nœuds de l'arbre) :

void afficher arbre(ArbreBR arbre)

C. Programme Principal:

Programmer un menu qui propose les fonctionnalités suivantes :

- 1. Créer un ABR.
- 2. Charger un fichier dans l'ABR : Afficher le nombre de mots lus dans le fichier.
- 3. Caractéristiques de l'ABR : Afficher le nombre de nœuds, la profondeur, et si l'ABR est équilibré.
- 4. Afficher tous les mots distincts par ordre alphabétique
- 5. Rechercher un mot : Afficher le n° de ligne, l'ordre dans la ligne, le n° de phrase pour chaque occurence.
- 6. Afficher les phrases contenant deux mots : Afficher toutes les phrases contenant les deux mots saisis.
- 7. Quitter : La mémoire allouée dynamiquement doit être libérée.

Bonus. Equilibrer l'ABR : Proposer à l'utilisateur d'équilibrer l'arbre si nécessaire

Consignes générales :

L'organisation du projet sera la suivante :

- Fichiers d'en-têtes arbre.h, liste.h et outils.h pour les déclarations des structures et fonctions
- Fichiers source arbre.c, liste.c et outils.c contenant la définition de chaque fonction
- Fichier source main.c contenant le programme principal.

Votre rapport (deux à quatre pages) devra contenir :

- le rappel des algorithmes vus en cours et utilisés dans le programme
- une description des fonctions et structures de données implémentées que vous avez choisi d'ajouter à celles qui demandées dans cet énoncé
- les difficultés rencontrées et vos choix pour y remédier